

项目计划书：证券投资策略与客户交易画像精准匹配研究

版本：V1.0
日期：2026-05-20


一、项目目标

构建一套可量化的客户与量化策略匹配方法，实现：

- 1. 基于传统统计特征的透明、可解释匹配方案（主交付物）
- 2. 基于深度学习嵌入的探索性验证方案（技术储备）
- 3. 两种方案的交叉验证与迭代优化机制

最终产出：可落地的匹配算法 + 前端弹窗话术示例 + 方法论报告。

二、总体架构：两阶段 workflow



三、阶段一：传统统计方向（主线）

3.1 workflow 细节

Step 1: 数据预处理

- 输入：量化策略绩效.xlsx（12个策略的时序交易记录）、模拟账户 A/B/C.xlsx（3个客户的持仓和交易明细）
- 清洗：统一时间格式、剔除停牌/退市股票（若有）、标准化买卖方向
- 输出：每个策略/客户的 (datetime, stock_code, action, volume, price) 标准表

Step 2: 特征提取（构建“隐藏分布”）

特征组	具体特征	维度	输出形式
行业偏好	28个申万一级行业的持仓市值占比（时间平均或期末）	28维	概率分布向量
换手率	年化换手率 = 总买入金额 / 平均持仓市值	1维	标量
平均持仓周期	所有已完结持仓的天数均值	1维	标量
持股集中度	前3大持仓市值占比（或赫芬达尔指数）	1维	标量
买卖对称性	总买入金额 / 总卖出金额（近一年）	1维	标量
波动偏好	日收益率的标准差（年化）	1维	标量

对于客户交易过少的冷启动情况，采用收缩估计（向市场平均或默认值正则化）。

Step 3: 相似度/距离定义

- 行业偏好距离：JS散度（对称、有界）

$$D_{JS}(p \parallel q) = \frac{1}{2}KL(p \parallel m) + \frac{1}{2}KL(q \parallel m), m = \frac{p+q}{2}$$

相似度: $\text{sim_ind} = 1 - D_{JS} / \ln 2$

- 标量特征相似度：归一化绝对差

$$\text{sim}_k = 1 - \frac{|x_{k,u} - x_{k,s}|}{\max(|x_{k,u}|, |x_{k,s}|, \epsilon)}$$

- 总相似度（加权求和）

$$\text{TotalSim}(u, s) = w_{\text{ind}} \cdot \text{sim}_{\text{ind}} + \sum_{k=1}^5 w_k \cdot \text{sim}_k$$

初始权重：行业0.3，换手率0.2，持仓周期0.2，集中度0.1，买卖对称性0.1，波动偏好0.1。

权重可调，并做敏感性分析。

Step 4: 匹配与过滤

- 对每个客户，计算与12个策略的 TotalSim，降序排列
- 附加硬性过滤条件（否则不推荐）：
 - 策略近一年收益率 > 客户近一年收益率
 - 策略近一年最大回撤 < 客户近一年最大回撤

Step 5: 可解释输出

为每个客户生成 Top-3 匹配策略，并输出如下JSON结构：

```

json
{
  "customer_id": "A",
  "matched_strategy": "S07",
  "total_similarity": 0.82,
  "dimension_breakdown": {
    "industry_js": 0.15,    // 越小越相似
    "industry_similarity": 0.85,
    "turnover_similarity": 0.92,
    "holding_period_similarity": 0.68,
    ...
  },
  "performance_gap": {
    "return_diff": +6.2,    // 策略比客户高6.2%
    "drawdown_diff": -3.1  // 策略回撤低3.1%
  },
  "popup_text": "策略S07与您的行业偏好相似度85%，换手率风格高度一致（92%），且近一<
#5E74>收益率高出6.2%、回撤低3.1%，建议订阅。"
}

```

3.2 潜在风险与缓解

风险	影响	缓解措施
客户交易笔数极少（<10）	行业分布估计不稳定	采用贝叶斯收缩：行业分布 = (客户数据 + $\alpha \times$ 市场平均) / (n + α)
策略与客户没有重叠行业	JS散度接近最大值，相似度低	这是合理结果，提示“风格差异较大，可考虑其他策略”
权重的选择主观	匹配结果对权重敏感	提供多组权重（如保守、均衡、激进）下的匹配稳定性表格
缺乏真实绩效反馈	无法验证匹配质量	建议后续A/B测试或问卷调查（见后）

四、阶段二：深度学习方向（辅线/技术储备）

4.1 定位说明

本阶段不用于生产，仅用于方法原型验证和未来技术储备。目的是：

- 探索交易序列的Token化及嵌入表达能力
- 在生成的大规模模拟数据上与统计方法交叉验证
- 为未来真实数据量扩充后提供备选方案

4.2 workflow 细节

Step 1: 模拟数据生成

- 以真实12个策略的统计特性（行业分布、换手率、持仓周期等）为原型，使用参数化模型生成 **500个模拟策略** 和 **200个模拟客户**。
- 每个实体生成 50~200 笔交易，保证时序逻辑（买入->卖出配对）基本合理。
- 数据生成代码公开，确保可复现。

Step 2: Token化设计

- 为避免词表过大，采用“行业代码_方向_数量等级”作为Token。行业使用28个一级行业，方向为BUY/SELL，数量等级分为3档（小、中、大）。
- 最大词表大小： $28 \times 2 \times 3 = 168$ ，稀疏性可控。

Step 3: 嵌入训练

- 使用 Word2Vec (Skip-gram with negative sampling) 训练 Token 嵌入，维度设 64。
- 每个客户/策略的向量：其所有交易Token的嵌入向量的平均值（或加权平均，按时间衰减）。
- 替代方案：Doc2Vec (PV-DM) 直接学习文档向量，可对比。

Step 4: 相似度计算与排序

- 使用余弦相似度计算客户向量与策略向量的匹配度。
- 输出每个客户的 Top-3 策略排序。

Step 5: 交叉验证与一致性分析

- 在相同的模拟数据上，运行阶段一的统计方法（使用完全一样的行业偏好和行为特征）。
- 比较两种方法对客户推荐的 Top- 1 策略一致率、Top- 3 重叠率、排序相关系数 (Spearman)。
- 若一致率 > 70%：认为统计方法可靠，深度方法可作为辅助确认。
- 若一致率 < 50%：选取典型不一致样本，进行深入归因：
 - 统计方法可能遗漏了买卖时点模式（如“先买后卖”的序列模式）
 - 深度方法可能学到了虚假的共现模式（由于生成数据的偏差）
 - 或需调整Token粒度/嵌入维度

Step 6: 归因与迭代

- 对不一致样本，人工检查其交易序列，判断哪种匹配更合理（可邀请金融专家辅助）。
- 若深度方法在若干案例上明显更优，则考虑：
 - 为统计方法增加新的特征（如买卖序列的Markov转移熵）
 - 或采用可解释嵌入（如线性自编码器 + SHAP）
- 记录迭代过程，形成技术文档。

4.3 潜在风险与缓解

风险	影响	缓解措施
模拟数据分布与真实偏离	深度方法在真实场景无效	模拟时以真实统计量为先验，并生成多个版本做鲁棒性检验
Token化方案不唯一	结果依赖于分词选择	测试2~3种Token方案（如个股级 vs 行业级，是否包含数量）
计算资源有限 深度方法“黑盒”	Word2Vec训练仍可在CPU上完成 主管可能质疑	使用gensim库，设定合理迭代次数 定位为探索研究，不替代统计方案；可提供可视化（t-SNE图）辅助理解

五、交付物清单

交付物	形式	对应阶段	截止时间
数据预处理及特征提取脚本	Jupyter Notebook + .py	阶段一	D+3
相似度计算与匹配模块	Python函数	阶段一	D+5
可解释话术生成器	Python函数 + 示例JSON	阶段一	D+7
阶段一报告（含匹配结果、权重敏感性、弹窗模拟图）	PDF / Markdown	阶段一	D+10
模拟数据生成器	Python脚本	阶段二	D+12
Word2Vec训练及嵌入匹配	Notebook	阶段二	D+18
交叉验证与一致性分析报告	PDF	阶段二	D+22
项目总结（含未来建议、质疑应对表）	PDF	全部	D+25

D为项目启动日。

六、可能遇到的质疑及应对

质疑	应对策略
“深度学习现阶段用不上，为何还要做？”	这是技术储备。我们已明确其不作为生产方案，而是用于验证统计方法的有效性，并为未来数据扩增后可能的性能飞跃做准备。目前行业领先的金融科技公司均保有此能力。
“生成数据不是真实数据，结论可信吗？”	生成数据是受控实验环境，可以精确知道真实匹配关系（如果有）。它帮助我们理解两种方法在不同数据特征下的行为，比纯理论推演更有说服力。同时我们会公开生成逻辑，供审计。
“如果两种方法结论不一致，听谁的？”	在没有真实客户反馈前，以 可解释性强、稳定性高 的统计方法为准。不一致样本会被详细分析并用于改进统计特征或深度模型结构。未来若上线A/B测试，以真实订阅转化率作为金标准。
“统计方法的权重是人工设定的，不够科学。”	初始权重基于金融常识；我们会展示多组权重的敏感性分析，证明主要匹配结果对权重在一定范围内不敏感。如果后续获得标签数据（如用户反馈），可以用贝叶斯优化或简单网格搜索调整权重。
“你们的深度方法为什么不用Transformer？”	当前生成数据规模（500策略+200客户）不足以训练Transformer，强行使用会导致严重过拟合。Word2Vec是序列嵌入的轻量级起点，如果未来真实数据达到数万客户，可升级至Transformer。
“如何验证匹配结果真正有效？”	本项目第一阶段交付的是一种 方法论和原型 。真正的效果验证需要在真实APP环境中做A/B测试：对匹配组用户推送策略，对比对照组的订阅转化率和留存率。我们将在报告中建议此项后续工作。

七、总结

本计划书提出的**两阶段架构**平衡了“当下可用”与“未来探索”：

- 阶段一提供**透明、可控、可解释**的统计匹配方案，直接满足主管需求。
- 阶段二作为**科研性验证**，不阻塞主线，但能展现团队的技术深度与严谨性。

通过交叉验证机制，两种方法相互校验，既避免盲目追求复杂模型，也不固守传统特征，为项目的长期演进打下坚实基础。

附录 A 金融术语对照

一、策略与交易相关

金融术语	数据科学类比	解释（在本项目中的含义）
量化策略	一个带规则的预测/决策模型	一套自动产生“何时买/卖哪只股票、多少股”的规则系统。比如：“当5日均线上穿20日均线时买入”。
交易数据	行为序列日志	每条记录包含：时间、股票代码、买卖方向、数量、价格。策略的交易数据就是它过去发出的每一条指令。
买卖指令	动作（action）	在某个时间点执行“买入”或“卖出”某个标的及数量。
持仓	当前持有的资产集合	账户里目前有哪些股票、分别持有多少股。可以看作一个“状态向量”。
仓位/仓位比例	权重（weight）	某只股票市值占总资产的比例。例如满仓 = 权重 1.0，半仓 = 0.5。
调仓	重新分配权重	从一种持仓状态变化到另一种状态，产生一系列买卖动作。

二、绩效与风险指标

金融术语	数据科学类比	解释
收益率	准确率 / 损失负值	资产增长的百分比。单期： $(期末 - 期初) / 期初$ ；多期可年化。是核心优化目标之一。
回撤	从峰值下跌的最大幅度	历史上资产从某个高点跌到后续最低点的最大百分比。类比模型训练中损失突然飙升的幅度。
夏普比率	信号噪比（均值/标准差）	$(平均超额收益) / 收益标准差$ 。衡量 风险调整后收益 ——每承担一单位波动能换来多少超额收益。
最大回撤恢复天数	从低谷回到峰值的迭代次数	发生最大回撤后，需要多长时间回到之前的高点。反映策略的“韧性”。
胜率	分类准确率（仅针对方向）	交易中盈利次数/总交易次数。注意：胜率高不代表总收益高（可能赚小钱亏大钱）。
盈亏比	平均正确收益 / 平均错误损失	平均每笔盈利 / 平均每笔亏损。与胜率一起描述策略的收益分布。

三、客户画像与匹配维度

金融术语	数据科学解释 / 匹配方法
交易风格	行为序列的统计特征：交易频率（日均换手率）、平均持仓天数、是否喜欢追涨杀跌（动量因子暴露）等。
持仓周期	从买入到卖出的持有天数。可做分布：短（1-5天）、中、长（>30天）。
行业偏好	行业是一个分类标签。统计客户历史持仓中各类行业的市值占比，形成一个 行业偏好向量 。策略同理。匹配可用余弦相似度或JS散度。
个股选择偏好	是个股级别的权重分布。由于股票数量巨大，常用 因子暴露 代替（如：偏好大盘股/小盘股、偏好低波动股等）。
风险承受能力	通常由客户历史最大回撤、仓位波动率等 反推 。匹配策略时，要求策略的历史回撤 $\leq$ 客户的历史回撤。
行为一致性	衡量客户自己的交易行为是否稳定。比如：是否有时频繁短线、有时长持？一致性高的人更容易匹配到固定风格的策略。

四、匹配对比时会用到的术语

金融术语	说明
超额收益	策略收益率 - 基准收益率（如沪深300指数）。用于判断策略是否真的“跑赢大盘”。
相对回撤	策略回撤 - 基准回撤。用于比较策略是否比大盘更抗跌。
滚动窗口	用过去N天的数据做匹配，而不是全量。比如用近60天、近120天分别匹配，看稳定性。
冷启动	新客户没有交易数据时的处理。可用问卷（风险测评问卷得到风格偏好），或推荐默认策略（均衡型）。

五、一句话速记表

金融词	记成数据科学词
收益率	模型的 R^2 或 $1 - \text{损失}$
回撤	损失函数的历史最大峰值跌幅
夏普比率	平均收益 / 收益波动率 $\approx$ 信号的信噪比
持仓	当前权重向量
调仓	权重更新策略
行业偏好	分类特征上的概率分布
胜率	二分类准确率（盈利=1，亏损=0）
盈亏比	正确预测的收益 / 错误预测的损失